

Picasso: Holistic Scene Reconstruction with Physics-Constrained Sampling

Xihang Yu, Rajat Talak, Lorenzo Shaikewitz, and Luca Carlone

<https://github.com/MIT-SPARK/Picasso>

<https://arxiv.org/abs/2602.08058>


RSS 2026

강재현

Robotics and AI for Spatial Estimation Lab

<https://raise-gachon.github.io>

Real-World Validation



The digital twin accurately predicts real-world behavior.

Importance

- 휴머노이드 등 로봇 물체 조작을 위해 simulator에서 수많은 시도를 통해 강화학습으로 제어 알고리즘을 개발하고 있음.



Importance






- 휴머노이드 등 로봇 물체 조작을 위해 simulator에서 수많은 시도를 통해 강화학습으로 제어 알고리즘을 개발하고 있음.
- Simulator의 성능이 좋아질 수록 학습 결과가 좋아짐.
- 하지만, simulation에서 학습한 결과가 실제 환경에서 동작하지 않는 Sim2Real Gap이 존재.
- 실제 환경을 simulator에 잘 옮길 수 있으면 이러한 문제를 해결할 수 있지 않을까?
 - Real2Sim

Importance (World Model)

World model (or digital twin)


- 주변 환경에 대한 이해를 통해 robot의 action이 환경에 미치는 영향을 예측 할 수 있음
- simulation-based planning이나 학습에 사용하고 싶음
- 그러나 occlusion과 depth noise 때문에 몇 mm 수준의 오차만 있어도 물리적으로는 불가능한 구성으로 환경을 추정

Problem (Huang, RSS 2026)



Problem

- Foundation 3D vision model (SAM 3D)
 - 개별 object 단위로 pose와 shape을 추정해서 전체적으로는 물리적으로 말이 안되는 조합으로 추정
 - 기하적으로는 맞지만 물리적으로는 말이 안되는 추정(occlusion이나 depth noise 때문)



SAM3D: physically implausible.
Red boxes: penetrations

Previous Methods

Gradient 기반 physics loss (PhysPose 등)

- Physics guided loss (non-penetration, stable contact)을 **penalty**로 넣고 gradient descent

$$\mathcal{L} = \mathcal{L}_{\text{data}} + \lambda_1 \mathcal{L}_{\text{pen}} + \lambda_2 \mathcal{L}_{\text{stab}} + \dots$$

- objective가 왜곡되어 **물리적으로 그럴듯한데 기하적으로 틀린 local minima**에 빠짐


Differentiable simulator 기반 (PhyRecon 등)

- 시뮬레이터의 모델링 오차와 수치 노이즈 때문에 brittle

제안 방법은


- physics를 미분하지 말고 constraint로 사용
- 가능한 경우를 샘플링하고 physics를 만족하지 못하는 경우 rejection하는 방식

Overview




- Pretrained(SAM 3D, CRISP) 모델의 pose/shape estimation 결과를 **재학습 없이 후처리(pose corrector)로 교정**

Overview




- 물체 간의 contact scene graph를 VLM(Gemini)으로 추론하고 DAG로 표현하여 최적화 차원을 줄임

Overview



- 물리 법칙을 penalty term이 아닌 **hard constraint**로 취급
 - Huang RSS 26과 같은 방향

Overview



- gradient descent 대신 **coarse-to-fine rejection sampling**으로 $SIM(3)$ 에서 탐색

Problem Formulation

N개의 물체가 있을 때 각 물체 i 에 대해 pose를 추정

- 입력은 RGB 이미지 I , depth map D , 물체별 mask M_i
- **Pose (+scale):** $T_i = (s_i' R_i' t_i) \in \text{SIM}(3)$, 카메라 프레임 기준.
 - SAM3D 같은 monocular estimator의 shape이 scale ambiguity를 갖기 때문에 SE(3)가 아니라 SIM(3)
- **Shape:** S_i , SAM3D의 추정치를 그대로 사용(고정)

Maximum Likelihood Estimation

$$\arg \max_{\{T_i, S_i\}_{i=1}^N \in \mathcal{F}} p(\{T_i, S_i\}_{i=1}^N \mid I, D, \{M_i\}_{i=1}^N)$$

- $\mathcal{F}$ 는 물리적으로 타당한 pose/shape의 집합
- 물리가 prior가 아니라 **feasible set**으로 들어간다는 게 기존 방법과 다름

Maximum Likelihood Estimation

- Likelihood를 chain rule로 pose와 shape으로 분리

$$p(\{\mathbf{T}_i, \mathbf{S}_i\}_{i=1}^N \mid \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N) =$$

$$\underbrace{p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)}_{\text{pose}} \times$$

$$\underbrace{p(\{\mathbf{S}_i\}_{i=1}^N \mid \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)}_{\text{shape}}$$

- Shape 항은 더 이상 전개하지 않고 pre-trained model의 추정치를 그대로 사용
 - 단일 추정이면 해당 shape으로 고정 (SAM 3D)
 - k개 후보면 uniform discrete distribution으로 취급 (CRISP)
 - 즉, Picasso는 shape은 안 고치고 pose만 고치는 corrector

Maximum Likelihood Estimation

- Pose항은 개별 object 단위로 분리
 - 각 object의 pose가 다른 object의 shape과 mask와 독립이기 때문

$$\begin{aligned}
 p(\{\mathbf{T}_i, \mathbf{S}_i\}_{i=1}^N \mid \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N) &= \\
 \underbrace{p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)}_{\text{pose}} &\times \underbrace{p(\{\mathbf{S}_i\}_{i=1}^N \mid \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)}_{\text{shape}} \\
 &= p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N) = \prod_{i=1}^N p(\mathbf{T}_i \mid \mathbf{S}_i, \mathbf{I}, \mathbf{D}, \mathbf{M}_i)
 \end{aligned}$$

- 각 object의 pose likelihood는 독립적이지만 전체 object estimation이 독립적으로 수행된다는 것은 아님
 - 제약 F를 통해 각 object는 couple되어 있음
 - Likelihood 계산은 object 별로 분리 가능하지만 constraint가 이를 묶음

Maximum Likelihood Estimation

- 개별 object의 pose에 대한 likelihood는 point cloud registration과 같음
- $A_i = \{a_{i,j}\}$ 를 mask M_i 안의 depth 3D 점들이라 하면 likelihood는 Gaussian과 같은 exponential family 노이즈 가정 하에 다음과 같음

$$p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N) = \prod_{i=1}^N p(\mathbf{T}_i \mid \mathbf{S}_i, \mathbf{I}, \mathbf{D}, \mathbf{M}_i) \rightarrow p(\mathbf{T}_i \mid \mathbf{S}_i, \mathbf{I}, \mathbf{D}, \mathbf{M}_i) \propto \exp \left(- \sum_{j=1}^{M_{\mathcal{A}_i}} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathbf{S}_i) \right)$$

- $d()$ 는 object frame으로 변환한 각 점 $a_{i,j}$ 과 object shape 사이의 거리

Maximum Likelihood Estimation

- 이제 negative log-likelihood를 취하면 MLE는 거리 최소화가 되고
- shape 표면에서 샘플링한 점 집합 $\mathcal{B}_i = \{b_{i,k}\}$ 에 대한 point-to-point distance가 됨

or Chamfer distance

$$\arg \max_{\{\mathbf{T}_i\}_{i=1}^N \in \mathcal{F}} \prod_{i=1}^N p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)$$

$$= \arg \min_{\{\mathbf{T}_i\}_{i=1}^N \in \mathcal{F}} -\log \prod_{i=1}^N p(\{\mathbf{T}_i\}_{i=1}^N \mid \{\mathbf{S}_i\}_{i=1}^N, \mathbf{I}, \mathbf{D}, \{\mathbf{M}_i\}_{i=1}^N)$$

$$= \arg \min_{\{\mathbf{T}_i\}_{i=1}^N \in \mathcal{F}} \sum_{i=1}^N \sum_{j=1}^{M_{\mathcal{A}_i}} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathbf{S}_i).$$


$$\begin{aligned} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathbf{S}_i) &\doteq d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathcal{B}_i) \\ &= \sum_{j=1}^{M_{\mathcal{A}_i}} \min_{1 \leq k \leq M_{\mathcal{B}_i}} \|s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i - \mathbf{b}_{i,k}\|^2 \end{aligned}$$

- 결국, pose likelihood 최대화 = SIM(3) point cloud registration**
 - 실제 구현에서는 Geman-McClure robust loss $\rho_{GM}(d) = d^2/(d^2 + \delta^2)$, $\delta = 0.05m$ 를 씌워 segmentation/depth 노이즈에 강건화

Constraints

$$\arg \max_{\{T_i, S_i\}_{i=1}^N \in \mathcal{F}} p(\{T_i, S_i\}_{i=1}^N \mid I, D, \{M_i\}_{i=1}^N)$$

- Static scene과 각 물체가 평면 위에 있음을 가정
 - 해당 평면은 point cloud measurement에서 3-point RANSAC으로 추정
- Physical constraint를 위해 물체/환경/자유공간을 SDF로 표현
 - SDF: surface와 점사이의 거리를 나타내는 함수
 - 거리가 **0보다 크면 surface 밖**, 0 보다 작으면 surface 안
 - Φ_i : SAM3D에서 얻은 각 물체 SDF
 - Φ_{env} : RANSAC에서 얻은 환경(table or ground)의 SDF
 - Φ_{free} : 3D point cloud measurement에서 얻은 자유공간의 SDF
 - Φ_{env} 와 Φ_{free} 는 3D point cloud에서 얻으므로 카메라와 같은 좌표계를 공유






Inter-Object Non-Penetration

- 물체 j 의 모든 표면점이 물체 i 의 SDF 밖에 있어야 함

$$\Phi_i(\mathbf{T}_i \cdot \mathbf{T}_j^{-1} \cdot \mathbf{b}) \geq 0, \quad \forall i \neq j, \quad \forall \mathbf{b} \in \mathcal{B}_j$$

물체 i 의 좌표계로 표현한 물체 j 의 표면점 $\mathbf{b}$




Object-Environment Non-Penetration

- 물체 i 의 모든 표면점이 환경 SDF 밖에 있어야 함

$$\Phi_{\text{env}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \quad \forall i, \quad \forall \mathbf{b} \in \mathcal{B}_i$$

물체 i 의 표면점 $\mathbf{b}$ 를 카메라 좌표계(environment 좌표계)로 변환



Object-Free-Space Non-Penetration


- 카메라 ray를 따라 depth 길이까지의 공간은 비어 있다고 관측된 것이므로, 물체가 없어야 함

$$\Phi_{\text{free}}(\underline{T_i^{-1} \cdot b}) \geq 0, \quad \forall i, \quad \forall b \in \mathcal{B}_i$$


물체 i의 표면점 b를 카메라 좌표계(free space 좌표계)로 변환



(a)



(b)



(c)

엄밀히는 물리 법칙이 아니라
visibility 제약

Contact (No Floating Objects)

- 각 물체는 환경 포함 최소 하나의 이웃과 tolerance δ 이내로 접촉하고 있어야 함

$$\underline{\forall i, \exists j \in [N] \setminus \{i\}, \exists \mathbf{b} \in \mathcal{B}_i \text{ s.t. } |\tilde{\Phi}_j(\mathbf{T}_i^{-1} \cdot \mathbf{b})| \leq \delta}$$

모든 물체 i 에 대하여 이웃 j 가 존재하는데 물체 i 의 surface 점 $\mathbf{b}$ 중 이웃 j 와 δ 이내의 거리에 있는 점이 있다

- $\tilde{\Phi}_j$ 는 $j = 0$ 이면 환경 SDF, 그 외에는 물체 j 의 world-frame(camera-frame) SDF

$$\tilde{\Phi}_j(\mathbf{y}) := \begin{cases} \Phi_{\text{env}}(\mathbf{y}), & j = 0, \\ \Phi_j(\mathbf{T}_j \cdot \mathbf{y}), & j \in [N]. \end{cases}$$

- 접촉의 존재만 요구하지 힘/모멘트 균형(정적 안정성)은 요구하지 않음

Physics-Constrained Pose Estimator Problem

- 지금까지 다룬 내용을 전부 합치면

$$\begin{aligned}
 & \arg \min_{\{\mathbf{T}_i\}_{i=1}^N \in \text{SIM}(3)^N} \sum_{i=1}^N \sum_{j=1}^{M_{A,i}} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathcal{B}_i) \\
 & \text{s.t. } \Phi_i(\mathbf{T}_i \cdot \mathbf{T}_j^{-1} \cdot \mathbf{b}) \geq 0, \forall i \neq j, \forall \mathbf{b} \in \mathcal{B}_j, \\
 & \quad \Phi_{\text{env}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \Phi_{\text{free}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \min_{j \in [N] \setminus \{i\}} \min_{\mathbf{b} \in \mathcal{B}_i} |\tilde{\Phi}_j(\mathbf{T}_i^{-1} \cdot \mathbf{b})| \leq \delta, \forall i.
 \end{aligned}$$

- $\text{SIM}(3)^N$ 차원 ($7N$ 차원) 위의 highly nonconvex 문제라서 최적화가 힘들: **Sampling 방식으로 풀겠다**

Rejection Sampling



- 가능한 configuration space에서 object pose를 sampling 함
- 해당 sample이 physical constraint를 위반하면 reject
 - inter-object, object-environment, and contact constraints는 libigl 라이브러리 사용
 - libigl : A simple C++ geometry processing library
 - object-free-space constraint
 - object를 depth map으로 rendering하고 depth map observation과 비교
- Constraint를 만족하는 sample 중 가장 cost 값이 낮은 것을 최종적으로 선택
- 문제는 sampling 해야 할 configuration space의 dimension이 너무 높다는 것

전체 scene을 graph로 근사하고 $7N$ 차원 문제를 N 개의 7차원 문제로 쪼개서 풀자

Contact Scene Graph

$$SG = (G, \theta), \quad G = (V, E), \quad V = \{v_0, v_1, \dots, v_N\}$$


- CSG는 고전적인 방법으로 객체별 contact 존재 유무를 graph로 표현
- v_0 은 환경(테이블 등), $v_1, \dots, v_N$ 은 물체, 각 노드의 파라미터 $\theta_v = (T_v, S_v)$ 는 추정하려는 변수
- Edge $(u, v) \in E$ 는 물리적 접촉을 표시, 두 표면 위에 $p_u = p_v$ 인 점이 존재하면 성립



Contact Scene Graph

$$SG = (G, \theta), \quad G = (V, E), \quad V = \{v_0, v_1, \dots, v_N\}$$

- CSG 추론은 VLM(Gemini)에 RGB + depth + mask를 주고 물어봄
 - Prompt: mask 인덱스로 adjacency list를 요구, "테이블이 root", "한 물체가 여러 물체에 지지될 수 있고 cycle도 가능"을 명시






Given the masks of objects, RGB image (second to the last) and depth map (last), give me contact dependency graph (adjacency list). Use the indices of the masks instead of text to represent the objects. Table is the root node. Note that an object may be supported by more than one object and there can be cycles in the graph.

Fig. 8: VLM prompt for contact scene graph generation.

Directed Acyclic Graph (DAG)

- CSG는 edge에 방향성이 없고 cycle을 구성할 수 있음
 - 상호 의존성이 있어 global한 표현이지만 이러한 graph에서 inference를 수행하는 것은 계산량이 많이 필요
- 대신, 환경 노드 v_0 를 root로 두고 각 edge를 node 탐색(breadth-first search) 순서 방향으로 orient
 - 상호 의존 정보는 소실 되지만 topological 순서로 한 물체씩 estimation 수행 가능
- Global 최적화 대신 local estimation의 연속을 선택



Directed Acyclic Graph (DAG)

- $P(i)$ 를 노드 i 의 부모 집합이라 하면 기존 문제가 N개의 subproblem이 됨
- 바뀌는 것은 제약의 범위가 모든 쌍 $\forall i \neq j$ 에서 부모만 $j \in \mathcal{P}(i)$ 로 축소.

$$\begin{aligned}
 & \arg \min_{\{\mathbf{T}_i\}_{i=1}^N \in \text{SIM}(3)} \sum_{i=1}^N \sum_{j=1}^{M_{A,i}} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathcal{B}_i) \\
 & \text{s.t. } \Phi_i(\mathbf{T}_i \cdot \mathbf{T}_j^{-1} \cdot \mathbf{b}) \geq 0, \forall i \neq j, \forall \mathbf{b} \in \mathcal{B}_j, \\
 & \quad \Phi_{\text{env}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \Phi_{\text{free}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \min_{j \in [N] \setminus \{i\}} \min_{\mathbf{b} \in \mathcal{B}_i} |\tilde{\Phi}_j(\mathbf{T}_i^{-1} \cdot \mathbf{b})| \leq \delta, \forall i.
 \end{aligned}
 \quad \Rightarrow \quad
 \begin{aligned}
 & \min_{\mathbf{T}_i \in \text{SIM}(3)} \sum_{j=1}^{M_{A,i}} d(s_i \mathbf{R}_i \mathbf{a}_{i,j} + \mathbf{t}_i, \mathcal{B}_i) \\
 & \text{s.t. } \Phi_i(\mathbf{T}_i \cdot \mathbf{T}_j^{-1} \cdot \mathbf{b}) \geq 0, \forall i \neq j, \forall \mathbf{b} \in \mathcal{B}_j, j \in \mathcal{P}(i), \\
 & \quad \Phi_{\text{env}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \Phi_{\text{free}}(\mathbf{T}_i^{-1} \cdot \mathbf{b}) \geq 0, \forall i, \forall \mathbf{b} \in \mathcal{B}_i, \\
 & \quad \min_{j \in \mathcal{P}(i) \setminus \{i\}} \min_{\mathbf{b} \in \mathcal{B}_i} |\tilde{\Phi}_j(\mathbf{T}_i^{-1} \cdot \mathbf{b})| \leq \delta, \forall i.
 \end{aligned}$$

- 처음에 root에 대해서 문제를 풀고 그 다음에 children node에 대해 문제를 푸는 식

Coarse-to-Fine Rejection Sampling

Initialization

- 입력은 기존 네트워크(SAM3D, CRISP)의 pose/shape 추정치
- Picasso는 이 추정치에서 초기값을 얻고 초기값 주변으로 sampling 범위를 탐색하여 pose(+scale)를 보정
- **Translation:** mask 내 depth point cloud의 평균 (5% outlier thresholding 후)
- **Scale:** masked depth의 평균 깊이와 네트워크 추정 pose/shape을 렌더링한 depth의 평균 깊이의 비율
- **Rotation:** initial 값이 없이 모든 경우의 수를 sampling 함

Coarse-to-Fine Rejection Sampling

Sampling strategy

- 7차원을 한 번에 sampling하지 않고 scale을 바깥 루프로 분리
 - 각 scale 가설마다 SE(3) registration subroutine을 돌리는 중첩(nested) 구조
- **Scale** (level 1–3)
 - $[0.5, 1.1]$ 구간에서 level당 $K = 5$ 개 uniform 샘플, 이후 best 후보 주변으로 refinement
- **Translation** (level 1–4)
 - 예측 shape으로 물체를 unit scale 정규화한 좌표계에서 추정: 물체 크기와 무관하게 같은 grid를 쓰기 위함
 - Level 1은 $[-0.5, 0.5]^3$ (unit scale 정규화 좌표)에서 $20^3=8000$ 개 uniform grid
 - level 2–4는 best 주변 5 samples/dim, 간격 $\tau_l \in \{0.05, 0.01, 0.005\}m$

Coarse-to-Fine Rejection Sampling

Sampling strategy

- 7차원을 한 번에 sampling하지 않고 scale을 바깥 루프로 분리
 - 각 scale 가설마다 SE(3) registration subroutine을 돌리는 중첩(nested) 구조
- Rotation** (level 1-4)
 - Level 1은 SO(3) 전체 공간에서 1024개 uniform sampling: local minima 탈출을 담당 (**global exploration**)
 - Level 2부터는 seed 회전 R_{seed} 의 tangent space에서 local perturbation

$$R_{\text{local}} = R_{\text{seed}} \cdot \exp(\omega), \quad \omega \in R^3, \omega_i \in [-\theta_{\text{max}}, \theta_{\text{max}}]$$

Level	Type	θ_{max}	θ_{step}	# rotations per seed
1	Global	—	—	1024
2	Tangent Space	30°	6°	515
3	Tangent Space	6°	2°	123
4	Tangent Space	3°	2°	19

Coarse-to-Fine Rejection Sampling

- Pseudo code

```
for scale_level in 1..3:
    scales = 5개 샘플      # level 1: [0.5, 1.1] uniform
                           # level 2-3: 이전 best 주변 refinement
    for s in scales:
        # SE(3): 4 levels (inner subroutine, scale s로 고정)
        L1: 1024 rotations × 8000 translations → top seeds
        L2: seed당 515 rotations ( $\pm 30^\circ$ ,  $6^\circ$ ) × translation ( $\pm 0.05$  m)
        L3: seed당 123 rotations ( $\pm 6^\circ$ ,  $2^\circ$ ) × translation ( $\pm 0.01$  m)
        L4: seed당 19 rotations ( $\pm 3^\circ$ ,  $2^\circ$ ) × translation ( $\pm 0.005$  m)
        loss(s) = 이 subroutine이 찾은 최소 robust Chamfer distance
    best_scale = argmin loss(s) # 다음 scale level의 중심
```

- 계산시 GPU parallelization 사용 (NVIDIA RTX 4090)

Coarse-to-Fine Rejection Sampling

Physics Constraint 적용은 sampling loop의 가장 끝

- 모든 sample에 대한 Chamfer loss 중 **최종 상위 16개** 후보에 대해서만 physics constraint 검사
 - Inter-object / environment / contact → libigl signed distance query
 - Free-space → voxel depth renderer로 렌더링 후 관측 depth와 비교
- Constraint 위반 후보는 reject, 통과한 것 중 최소 loss를 가지는 sample을 선택
- 16개 전부 위반하면 best-scoring pose를 그냥 반환 (soft fallback)
 - fallback이 발동하면 출력은 물리적으로 invalid
- 즉, Picasso는 constrained 최적화를 푸는 게 아님
- unconstrained 문제의 top-16 중 feasible한 것 고르는 것

(Proposed) Physics Metric

Scene Plausibility Score (SPS)

- 추정된 pose/shape으로 digital twin을 만들어 PyBullet에 임포트
- $T=20$ 스텝 (timestep $1/240$ s) 진행 후 각 물체의 운동에너지를 잼
 - mass = 1kg, inertia = identity로 설정

$$S_{SPS} := \frac{1}{2} m, v^T v + \frac{1}{2} \omega^T J, \omega, \quad m = 1, \text{kg}, J = I_3$$

- 어떤 유형의 물리 위반이든 최종적으로 운동에너지로 수렴하기 때문
 - 관측된 장면은 정적이므로 reconstruction이 잘 되었다면 시뮬레이션에서도 정지해 있어야 함
 - Penetration이 있으면 solver가 물체를 밀어내며 속도가 생기고, 물체가 떠 있으면 낙하하며 속도가 생기고, 불안정하면 넘어지며 속도가 생김
- 논문에서 제안한 metric

Evaluation Metrics (기존)

NPS (Non-Penetration Score): 기존 연구에서 가져온 metric을 수정

- 물체 i 의 주변 개체 집합에 대해 가장 깊은 침투 깊이 $p(i, j)$ 를 SDF로 계산하고 평균을 냄

ADD-S

- GT 모델의 각 점에서 추정 모델의 가장 가까운 점까지의 평균 거리

ADD-S (AUC)

- 단일 평균값은 outlier에 지배되므로, threshold τ 를 움직이며 성공률 곡선을 그리고 그 아래 면적을 잼

OC (observable correctness)

- GT 없이, 추정 결과가 관측된 point cloud를 노이즈 허용치 안에서 설명하는지 검사한 통과 비율(%)

Experiments: CRISP with Picasso

두 모델을 사용

- CRISP-Real: 실제 데이터(YCB-V dataset)로 학습
- CRISP-Syn: 가상 데이터(4,200 장)으로 학습
 - BlenderPro로 생성한 기존 연구의 데이터

TABLE I: Evaluation results on the ADD-S (m) and ADD-S (AUC) metrics for the YCB-V dataset. **Best**, **Second-best**.

Method	ADD-S ↓		ADD-S (AUC) ↑		
	Mean	Median	1 cm	2 cm	3 cm
CosyPose [31]	0.010	0.007	0.30	0.56	0.68
BundleSDF [51]	0.014	0.012	0.14	0.37	0.55
GDRNet++ [34]	0.013	0.011	0.22	0.43	0.58
CRISP-Real [46]	0.009	0.004	0.44	0.58	0.75
CRISP-Syn [46]	0.015	0.010	0.21	0.41	0.55
CRISP-Syn+GD	0.015	0.011	0.21	0.41	0.55
CRISP-Syn+GICP	0.012	0.003	0.44	0.58	0.67
CRISP-Syn+Picasso	0.008	0.003	0.52	0.69	0.77
CRISP-Real+Picasso	0.008	0.003	0.53	0.70	0.78

TABLE II: Evaluation results on the SPS, NPS (mm), observable correctness, and runtime on the YCB-V dataset. **Best**, **Second-best**.

Method	SPS ↓	NPS ↓	OC ↑	run time (s) ↓
CRISP-Real	9.05	4.57	36%	/
CRISP-Syn	9.36	6.38	15%	/
CRISP-Syn+GICP	9.56	4.70	42%	0.03
CRISP-Syn+Picasso	8.71	3.99	55%	0.35
CRISP-Real+Picasso	8.77	3.95	55%	0.33

- 왜 CRISP-Syn이 더 잘되는지에 대한 분석은 없음

Experiments: SAM3D with Picasso

TABLE III: Comparison of methods across 12 YCB-Video trajectories. ADD-S (mm), SPS (physics loss), NPS (mm). S: SAM3D. S+P-w/o PC: SAM3D+Picasso w/o physics constraints. S+P: SAM3D+Picasso. **Best**.

Trajectory	ADD-S ↓			SPS ↓			NPS ↓		
	S[9]	S+P -w/o PC	S+P	S[9]	S+P -w/o PC	S+P	S[9]	S+P -w/o PC	S+P
traj_48	16.97	8.98	9.06	15.32	5.38	5.16	10.13	2.82	2.76
traj_49	29.53	26.74	26.59	4.21	2.32	2.14	7.94	5.03	4.72
traj_50	11.77	19.91	20.48	1.60	0.86	1.14	5.65	3.86	3.53
traj_51	13.25	7.40	7.84	8.51	2.87	3.01	7.31	2.37	2.13
traj_52	17.78	6.28	6.76	6.16	0.12	0.12	16.53	3.20	2.91
traj_53	16.07	5.17	5.46	6.50	0.04	0.04	11.51	3.23	2.98
traj_54	22.94	10.22	10.19	10.77	4.53	4.69	10.70	2.51	2.47
traj_55	68.73	9.53	10.23	3.60	0.63	0.63	11.11	2.16	1.95
traj_56	16.74	9.21	9.45	4.42	1.48	1.19	9.01	2.77	2.67
traj_57	19.48	6.88	6.95	2.08	0.48	0.39	5.12	1.94	1.69
traj_58	13.06	7.11	7.31	3.43	3.18	2.73	10.27	4.16	3.86
traj_59	13.81	6.11	6.46	3.54	1.03	1.02	6.26	1.96	1.84
Overall	21.68	10.29	10.56	5.84	1.91	1.85	9.29	3.00	2.79

- S vs S+P-w/o PC: Physical constraint가 없는 경우에도 기하적 성능(ADD-S)과 Physical constraint(SPS, NPS)가 좋아짐
 - Sampling strategy의 효과가 매우 크다는 것을 알수 있음
- Physics constraint를 적용하면 SPS, NPS는 좋아지지만 ADD-S는 안 좋아짐
 - 기하와 물리 사이의 tradeoff를 확인 가능

Picasso Dataset


- The Picasso dataset contains 10 real-world **contact-rich** scenes
 - ground truth annotations
 - a metric to quantify physical plausibility



Experiments: Picasso Dataset

TABLE IV: Comparison of methods across 10 Picasso sequences. ADD-S (mm), SPS (physics loss), NPS (mm). SAM3D: SAM3D with RGB input, SAM3D-PM: SAM3D with both RGB and pointmap input. **Best**, **Second-best**.

Method	ADD-S (mm) ↓		ADD-S (AUC) ↑			SPS ↓	NPS ↓
	Mean	Median	1 cm	2 cm	3 cm		
SAM3D-PM	11.45	6.49	33.59	56.17	68.35	8.91	5.67
+GICP	7.23	5.77	43.82	69.04	78.93	8.58	4.32
+Picasso (Ours)	7.84	5.18	47.07	70.99	79.73	6.59	3.50
SAM3D	11.71	7.52	30.60	53.61	66.53	8.50	5.23
+Picasso (Ours)	7.57	4.95	47.38	70.91	79.77	7.63	3.74



- vs SAM3D: 모든 메트릭에서 큰 폭 개선
- vs GICP: ADD-S (Mean) 빼고 더 좋은 결과
 - ADD-S (median)은 개선되었는데 ADD-S (mean)은 안 좋음
 - Outlier의 에러가 더 컸다고 볼 수 있음

Conclusion

- 기하학적으로 정확한 재구성도 물리적으로 불가능할 수 있다는 문제 제기 (penetration, floating, unstable)
- Physics를 loss가 아닌 hard constraint로 사용하여 gradient 대신 rejection sampling 사용
- VLM 기반 Contact Scene Graph → DAG 근사 → 물체별 순차 SIM(3) 탐색의 구조
- 재학습 없는 pose corrector라고 할 수 있음, shape은 고정

Key takeaways

- 성능 개선의 대부분은 global sampling이지 physics가 아님
 - ADD-S 21.7 $\rightarrow$ 10.3 (sampling만) $\rightarrow$ 10.6 (physics 추가, 기하는 오히려 소폭 후퇴)
- Physics의 실제 역할은 top-16 후보의 검증
- Physics plausible은 절대적으로 보장되는 것은 아님
- Sim-to-real에 유용한 결과를 보임
 - CRISP-Syn+Picasso $\approx$ CRISP-Real (+Picasso)

Limitations

- hard constraint + rejection은 gradient 정보를 전혀 활용하지 못하니 sampling이 촘촘해야 함 (coarse-to-fine으로 보완)
- 계산량 감소를 위한 오차 전파의 비대칭성
 - 부모의 pose 오차는 자식의 오차에 영향을 주지만 반대는 아님
 - 즉, global 최적화보다는 성능이 낮을듯
- VLM에 의존적
- 최적화 과정에 uncertainty가 고려 안됨
- Physic constraint에 힘, torque, friction 등은 빠져 있음
 - 닿아 있지만(contact) 넘어지는 경우도 발생 가능

Failure Cases




Fig. 11: A failure case due to inaccurate shape prediction.




Fig. 13: Approximation of contact scene graph can lead to failure in downstream inference.



Fig. 12: A failure case due to noisy and partial depth point clouds.