


NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis

Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik,
Jonathan T. Barron, Ravi Ramamoorthi, Ren Ng

유병훈

Introduction




- Novel view Synthesis – 촬영되지 않은 새로운 시점의 이미지를 합성하는 문제
- NeRF는 장면을 5D 함수 $F_{\Theta}: (x, d) \rightarrow (c, \sigma)$ 로 표현
- 여러 입력 영상과 카메라 포즈만으로 연속적인 3D 장면 표현을 최적화

Previous Methods

- Mesh 기반 방법: 이미지 재투영 오차를 이용한 직접 최적화가 어렵고, 고정된 topology의 초기 mesh가 필요함
- Voxel / MPI 기반 방법: 복잡한 형상과 재질을 자연스럽게 표현할 수 있지만, 고해상도에서는 시간과 메모리 비용이 급격히 증가함
- Neural implicit shape: 연속적인 고해상도 geometry를 표현할 수 있지만, 기존 방법은 단순한 형상에 제한되며 결과가 과도하게 부드러워지는 문제가 있음


Overview



- 1) 카메라 ray를 따라 3D point들을 sampling
- 2) 각 point의 위치(x, y, z)와 시선 방향(θ, ϕ)을 MLP에 입력하여 color와 density를 예측
- 3) Volume rendering을 통해 각 point의 값을 누적하여 pixel color를 합성
- 4) 합성된 이미지와 ground truth의 오차를 최소화하도록 network를 최적화

Camera pose

$$r(t) = o + t d$$



- 카메라 위치 o 와 pixel별 방향 d 가 정해지면 ray가 생성됨
- t 값을 sampling하면 3D 위치 $x_i = o + t_i d$ 가 자동으로 결정됨
- 따라서 MLP에는 각 x_i 와 동일한 ray direction d 가 입력됨

Scene Representation

$$F_{\Theta}(x, d) = (c, \sigma)$$

Input

$x = (x, y, z)$
ray 위에서 sampling된 3D 위치


$d = (\theta, \varphi)$
해당 point를 바라보는 방향

Output

$\sigma(x)$
volume density
물체가 존재하는 정도


$c(x, d)$
view-dependent RGB color
시점에 따라 달라지는 색

Scene Representation



- Density는 위치에서, color는 위치와 방향에서 예측한다
- 물체의 위치는 시점이 바뀌어도 같지만, 반사와 highlight는 시점에 따라 달라진다.

Volume rendering



- 각 sample은 color c_i 와 density σ_i 를 출력
- 최종 pixel은 단순 평균이 아니라, 카메라와 가까운 sample부터 투명도를 누적하는 front-to-back alpha compositing으로 계산
- 앞에서 ray가 멈출 확률이 높으면 뒤 sample의 색은 거의 보이지 않는다.

Formula

$$C(r) = \int_{t_n}^{t_f} T(t) \cdot \sigma(r(t)) \cdot c(r(t), d) dt$$

- **$T(t)$** : camera에서 위치 t 까지 다른 물체에 가려지지 않고 도달할 확률인 **transmittance**
- **$\sigma(r(t))$** : 그 위치에서 ray가 멈출 정도를 나타내는 **volume density**
- **$c(r(t), d)$** : 그 지점이 viewing direction d 에서 방출하는 **RGB color**

$$T(t) = \exp\left(-\int_{t_n}^t \sigma(r(s)) ds\right)$$

- $T(t)$ 는 t 까지 지나온 density를 적분한 뒤 $\exp(-\cdot)$ 를 적용해 계산한다. 따라서 앞쪽에 높은 density가 있으면 $T(t)$ 가 빠르게 작아져 뒤쪽 sample의 color contribution이 감소한다.

Formula

실제 계산에서는 적분을 N개의 sample 합으로 근사한다

$$\hat{C}(r) = \sum_{i=1}^N w_i c_i$$

$$w_i = T_i \alpha_i$$

$$\alpha_i = 1 - \exp(-\sigma_i \delta_i)$$


$$T_i = \prod_{j=1}^{i-1} (1 - \alpha_j)$$

- α_i : sample i에서 ray가 멈출 확률
- T_i : 그 sample까지 살아서 도달할 확률
- w_i : 두 값을 곱한 값으로 최종 pixel에서 color c_i 가 차지하는 비율
- 모든 sample의 weighted color를 합하면 rendered pixel $\hat{C}(r)$ 을 얻는다.

Positional encoding

- 기본 MLP는 낮은 주파수의 smooth한 함수를 먼저 학습하는 경향
- 좌표를 그대로 입력하면 얇은 구조와 sharp texture가 흐려짐
- NeRF는 좌표 p 를 여러 주파수의 $\sin$ 과 $\cos$ 값으로 mapping해 network가 고주파 변화를 쉽게 표현하도록 함

$$\gamma(p) = [\sin(2^k \pi p), \cos(2^k \pi p)]_{k=0}^{L-1}$$



Hierarchical sampling

빈 공간 대신 surface 주변에 계산을 집중

1. Coarse pass



$N_c = 64$ samples를 ray 전체에서 stratified sampling
→ coarse weights로 중요한 구간의 PDF 생성

2. Fine pass



$N_f = 128$ samples를 importance sampling
→ 최종 rendering은 coarse + fine samples를 함께 사용

Experiments

Method	Diffuse Synthetic 360° [41]			Realistic Synthetic 360°			Real Forward-Facing [28]		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
SRN [42]	33.20	0.963	0.073	22.26	0.846	0.170	22.84	0.668	0.378
NV [24]	29.62	0.929	0.099	26.05	0.893	0.160	-	-	-
LLFF [28]	34.38	0.985	0.048	24.88	0.911	0.114	24.13	0.798	0.212
Ours	40.15	0.991	0.023	31.01	0.947	0.081	26.50	0.811	0.250

- 정량 결과는 NeRF가 특히 복잡한 synthetic 에서 강하다는 것을 보여준다.

Ablation Study

	Input	#Im.	L	(N_c, N_f)	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
1) No PE, VD, H	xyz	100	-	(256, -)	26.67	0.906	0.136
2) No Pos. Encoding	$xyz\theta\phi$	100	-	(64, 128)	28.77	0.924	0.108
3) No View Dependence	xyz	100	10	(64, 128)	27.66	0.925	0.117
4) No Hierarchical	$xyz\theta\phi$	100	10	(256, -)	30.06	0.938	0.109
5) Far Fewer Images	$xyz\theta\phi$	25	10	(64, 128)	27.78	0.925	0.107
6) Fewer Images	$xyz\theta\phi$	50	10	(64, 128)	29.79	0.940	0.096
7) Fewer Frequencies	$xyz\theta\phi$	100	5	(64, 128)	30.59	0.944	0.088
8) More Frequencies	$xyz\theta\phi$	100	15	(64, 128)	30.81	0.946	0.096
9) Complete Model	$xyz\theta\phi$	100	10	(64, 128)	31.01	0.947	0.081

- Positional encoding 제거: high-frequency detail 표현이 크게 약해짐
- View dependence 제거: specular reflection 같은 non-Lambertian effect 표현 불가
- Hierarchical sampling 제거: 성능 하락, sample efficiency 감소

Conclusion

- NeRF는 장면을 연속적인 5D radiance field로 표현하고, volume rendering을 통해 새로운 시점의 이미지를 생성한다. 전체 렌더링 과정이 미분 가능하므로, 별도의 3D supervision 없이 RGB 이미지와 camera pose만으로 장면의 geometry와 view-dependent appearance를 학습할 수 있다.

Limitations

- Scene마다 긴 최적화가 필요하며, 한 pixel을 렌더링하기 위해 많은 MLP query를 수행해야 한다.