

A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning

Stéphane Ross(Robotics Institute,Carnegie Mellon University) ,
Geoffrey J. Gordon(Machine Learning Department, Carnegie Mellon University),
J. Andrew Bagnell(Robotics Institute, Carnegie Mellon University)


Overview

1. Before DAgger
2. What is DAgger
3. Why does DAgger Reduce Error to $O(T\epsilon)$?
4. Experimental Results
5. Discussion
6. Future Work

1. Before DAgger: Behavior Cloning

- Real World에서 시행착오를 반복하는 RL은 비용과 위험이 큼
- Expert Dataset은 비교적 안전하게 수집 가능
 - >> Behavior Cloning은 모방학습 -> 일반적인 지도학습 문제로 바뀜
- BC가 단순하고 실용적인 접근
- 단점은 전문가가 방문한 상태에서만 학습함
 - > 문제는 모델의 성능이 아닌 학습 데이터가 전문가 분포에서만 수집됨

1. Before DAgger: Behavior Cloning



그런데 실제 주행에서도 학습때와 같은 상태만 만날까?

1. Before DAgger: Behavior Cloning

학습 구조

Camera Image -> Policy -> Steering Angle

학습 데이터

$$D_{\text{expert}} = \{(s, a^*)\}$$

목표

$$\min_{\pi} \mathbb{E}_{s \sim d_{\pi^*}} [\ell(\pi(s), \pi^*(s))]$$



장점

- 1) 구현이 간단함
- 2) 기존 지도학습 알고리즘 사용 가능
- 3) 로봇이 직접 실패하며 탐색할 필요가 없음
- 4) 전문가 행동을 그대로 학습 가능

그러나 학습 오차는 전문가가 방문한 상태 분포에서만 측정됨

1. Before DAgger: Behavior Cloning

- Training(Expert Demonstrations)
- Deployment(Test)

$S1 \rightarrow S2 \rightarrow S3 \rightarrow S4 \rightarrow S5$

$S1 \rightarrow S2 \rightarrow S3$



$S3'$



$S4'$



$S5'$

$$d_{\pi^*}(s) \neq d_{\pi}(s)$$

Training Distribution $\neq$ Test Distribution
정책의 예측이 다음 입력 상태를 바꾼다

1. Before DAgger: Background

1) Imitation Learning(모방학습)

- . Learn to imitate expert actions
- . Does not require manually designing a reward function, unlike Reinforcement Learning(RL)

2) Behavioral Cloning(행동 복제)

- . The simplest form of Imitation Learning
- . Learns directly from expert demonstrations using Supervised Learning

1. Before DAgger: Background

3) Covariate Shift(공변량 이동)

- Starts from the mismatch between the training and real-world state distributions
- Ultimately leads to error accumulation


4) Error Accumulation(오차 누적)

- A phenomenon where small prediction errors accumulate over time and lead to increasingly larger errors

1. Before DAgger: Motivation

$t=1$


학습된 상태와 비슷함



1. Before DAgger: Motivation

$t=2$


작은 조향 오차 발생



1. Before DAgger: Motivation

$t=3$


학습 데이터에서 벗어난
상태에 진입




1. Before DAgger: Motivation

$t=4$

복구 행동을 학습한
적이 없음



1. Before DAgger: Motivation



BC의 문제는 오차가 다음 입력의 분포를 바꾼다는 것

2.What is DAgger

- A method for improving the policy in imitation learning by adding the states visited by the learner during execution to the training dataset.

2. What is DAgger(Algorithm)

Initialize $D \leftarrow \emptyset$.

Initialize π^1 to any policy in Π .

for $i = 1$ to N do Let $\pi_i = \beta_i \pi^* + (1 - \beta_i) \pi^i$.

 Sample T -step trajectories using π_i .

 Get dataset $D_i = \{(s, \pi^*(s))\}$ of visited states by π_i and actions given by expert.


 Aggregate datasets: $D \leftarrow D \cup D_i$.

 Train classifier π^{i+1} on D .

end for Return best π^i on validation.

2.What is DAgger

DAgger (Dataset Aggregation) Pipeline



DAgger 핵심 아이디어

현재 학습 정책이 실제로 방문하는 상태에서 전문가의 행동을 라벨로 받아 데이터에 계속 추가하고, 전체 데이터를 이용해 정책을 반복 학습



전문가 (π^*)



학습된 정책 ($\hat{\pi}_i$)



상태 (s_t)



전문가 행동 (a_t^*)

2.What is DAgger

- Next policy

$$\pi^{i+1} = \arg \min_{\pi \in \Pi} \sum_{(s, a^*) \in D} \ell(\pi(s), a^*)$$

- Loss function

$$\ell(\pi(s), a^*)$$

- Classification

$$\ell = \begin{cases} 0, & \pi(s) = a^* \\ 1, & \pi(s) \neq a^* \end{cases}$$

- Continuous control(MSE)

$$\ell = (\pi(s) - a^*)^2$$

3. Why does DAgger Reduce Error to $O(T\epsilon)$?

if $T = 10$ and $\epsilon = 0.1$ (10%의 오차)

첫 오류시: $s_t \rightarrow s_{t+1}$

t번째 실수: 최대 $T - t + 1$

but Behavioral Cloning의 경우

Step1 실수 -> Step2 처음 보는 상태

-> Step3 처음 보는 상태 -> ...

실수한 시점	영향을 받는 남은 Step 수
1	T
2	T-1
3	T-2
4	T-3
...	...
T	1

3. Why does DAgger Reduce Error to $O(T\epsilon)$?

실수한 시점	영향을 받는 남은 Step 수
1	10
2	9
3	8
4	7
...	...
10	1

-> 모두 더하면

$$10 + 9 + \dots + 1 = \frac{10 \times 11}{2} = 55$$

일반적으로

$$\text{Total Error} \leq \sum_{t=1}^T (T - t + 1)\epsilon = \epsilon \cdot \frac{T(T+1)}{2}$$

빅오 표기론

$O(T^2\epsilon)$

>> Error Propagation

3. Why does DAgger Reduce Error to $O(T\epsilon)$?

DAgger -> 한 번 실수해서 도달한 상태도 다음 학습 데이터에 추가

- 다음 반복에서는 해당 상태가 더 이상 완전히 보지 못한 상태가 아니다.
- 정책이 실제로 방문하는 상태에서의 오류를 줄이기 때문에, 전체 오류 누적이 $O(T^2\epsilon)$ 가 아니라 $O(T\epsilon)$ 수준으로 줄어든다.

빅오 표기법으로

$O(\epsilon T)$

4. Experimental Results

1) Super Tux Kart Steering Control

1) Super Mario Bros Playing

1) Handwriting Recognition

4. Experimental Results

1) Super Tux Kart Steering Control

- DAgger가 기존 supervised imitation learning보다 실제 주행 상황에서 오류 복구 능력이 좋은지 확인
- 사용 모델: Linear Controller, Ridge Regression
- 입력: 게임 이미지 feature (800*600 -> 25*19로 resize)
- 출력: Steering값(5hz로 업데이트)




Figure 1: Image from Super Tux Kart's Star Track.


4. Experimental Results

1) Super Tux Kart Steering Control

- 비교 알고리즘 : SMILe, Supervised Learning

- 측정 지표: Lap당 track 이탈 횟수

- SMILe = Stochastic Mixing Iterative Learning
- - imitation learning 계열 알고리즘
- - expert와 learner(policy)의 행동을 확률적으로 섞어서 학습 데이터를 모음



4. Experimental Results

2) Super Mario Bros Playing

- DAgger가 복잡한 sequential decision problem에서도 좋은 policy를 만드는지 확인

사용 모델: Linear SVM 4개(행동 4개)

입력: 27,152개의 sparse binary feature
(마리오 주변 grid 정보,
적 위치, 장애물, 이전 행동 기록)

출력: 4 binary action(left/right/jump/speed)




Figure 3: Captured image from Super Mario Bros.

4. Experimental Results

2) Super Mario Bros Playing

- 비교 알고리즘 : SMILe, Supervised Learning
SEARN, DAgger(D0,...,D0.9)

- 평가 지표: State당 평균 이동거리(최대 4300)



- SEARN =Search-based Efficient Aggregation for Imitation Learning
- - expert policy와 learned policy를 점진적으로 섞는 알고리즘

4. Experimental Results

3) Handwriting Recognition

- DAgger가 imitation learning뿐 아니라 structured prediction 문제에도 적용 가능한지 확인


- . 사용 모델: Linear SVM
- . 데이터: Taskar et al. handwriting dataset
- . 구성: 약 6,600 words, 약 52,000 characters

4. Experimental Results

3) Handwriting Recognition

- 비교 알고리즘 : No Structure, Supervised, SMILe, SEARN, DAgger
- 평가 지표: Character accuracy

방법	방식	성능 (Accuracy)
No Structure	구조 정보 없이 기본 학습 (baseline)	약 82.0%
Supervised Learning	Expert 데이터로 지도학습 (Behavioral Cloning)	약 83.6%
SMILe	Expert/Learner stochastic mixing + iterative learning	약 84.5 ~ 84.7%
SEARN (일부 설정)	Policy mixing 기반 iterative imitation learning	약 85.2 ~ 85.4%
DAgger	Dataset Aggregation + expert query + 재학습	약 85.5%



4. Experimental Results

실험 결과

실험	일반 지도학습 문제	Dagger가 수집한 추가 상태	결과
Super Tux Kart	정상적인 전문가 주행만 학습	트랙 가장자리와 복구 상태	낙하 횟수 0
Super Mario	전문가가 정상적으로 통과하는 상태만 학습	장애물에 끼거나 잘못 이동한 상태	평균 이동 거리 약 3,030
손글씨 인식	이전 정답 문자를 입력으로 학습	이전 예측이 잘못된 상태	문자 정확도 약 85.5%

4. Experimental Results

1. 데이터 양보다 데이터 분포가 중요하다
 - 1,2 실험에서 supervised는 전문가 데이터를 늘려도 성능 개선이 안 되었음
2. 실패 상태를 학습해야 한다.
 - DAgger는 실패 상태에서 복구 행동을 학습함
3. 단순 모델로도 효과가 있었다.
 - 선형 회귀, 선형 svm을 모델로 사용

5. Discussion: Advantages

1. Distribution Shift 직접 해결
2. 실수 후 복구 행동 학습 가능
3. 오류 누적 줄일 수 있음
4. 기존 지도학습 모델 그대로 사용 가능
5. 구조가 단순하고 이론적 근거가 있음

5. Discussion: Limitations

1. 전문가 반복 호출
2. 초기 정책 실제 실행시 위험부담
3. 전문가 품질에 크게 의존
4. 데이터셋의 규모 증가
5. 장기 보상 최적화를 직접하진 않음

5. Discussion: Meanings

당시 생각

- Expert Data 많이 모르면 로봇도 잘 할 것 같음 ->> Fail

Expert Data -> Safe States + Safe Action

Real Robot -> Safe States + Error States + Recovery States

“자신이 실패하는 상황을 학습하지 못했음”의 생각으로 접근한 것이 포인트

5. Discussion: Features

1. Expert distribution이 아니라 policy distribution에서 학습
2. 실패 상태와 복구 상태를 데이터에 포함
3. Robot Learning을 실험실 밖으로 확장
4. $O(T^2\epsilon) \rightarrow O(T\epsilon)$ 성능 보장

6. Future work

1. 더 정교한 구조적 예측 방법
 - 현재 논문에선 greedy one-pass decoding 사용
 - 향후 Multi-pass decoding, Beam search 같은 정교한 방법 적용
2. Expert action 보단 expert cost function을 학습하기
 - 전문가 행동 자체를 직접 모방하는 방식에서 확장
 - Inverse Optimal Control을 통해 전문가의 판단 기준인 cost function을 학습
 - Planner가 cost function을 바탕으로 행동 결정
3. 장기 성능 보장
 - 행동 하나가 미래에 어떤 영향을 미치는지는 다루지 않고 있음
 - cost-to-go(이 행동을 했을 때 앞으로 발생할 전체 비용)

THANKS