

AIM-SLAM: Dense Monocular SLAM via Adaptive and Informative **M**ulti-View Keyframe Prioritization with Foundation Model

Jinwoo Jeon¹, Dong-Uk Seo¹, Eungchang Mason Lee², Hyun Myung^{1*}

ICRA 2026

Demo

Intro

- Visual SLAM
 - camera pose를 추정하기 위해 **handcrafted features**를 활용하고 정확한 **camera calibration**을 요구하는 전통적인 **geometric pipeline**에 의존함
- recent GFM(Geometric-aware Foundation Model)
 - DUS3R, MAS3R, VGGT
 - 이들은 uncalibrated RGB 입력을 통해 dense 3D pointmap들을 직접적으로 예측하며 설득력있는 대안들로 떠오름

⇒ 이러한 GFM의 이점을 활용하여, uncalibrated monocular image들로 dense reconstruction을 하는 SLAM 시스템으로 확장하고자 함

- GFM이 받을 수 있는 입력이 늘어나면서, 몇몇 접근법들은 SLAM에 multi-view reasoning을 통합함 (e.g. submap 활용 등)
 - 이러한 구조는 좋은 성능을 보였지만, 이웃하는 frame들을 간단히 묶는 방식은 GFM의 multi-view constraints의 잠재력을 최대한으로 이끌어내지 못했으며, 제한된 geometric information gain을 가지는 중복된 frame들을 포함

⇒ 전통적인 SLAM 방법론들이 map representation과 covisibility에 기반하여 multi-view keyframe selection 방법들을 다뤄왔지만, GFM 기반 SLAM에서는 이러한 부분이 아직 연구되지 않았고, 더 원칙적인 keyframe prioritization의 필요를 강조

Classical and Learning-based Visual SLAM

- Indirect methods
 - sparse salient primitive(e.g. points, line segments)의 reprojection error를 최소화하여 motion 추정
- Direct methods
 - pixel intensities에 따른 photometric error를 최소화하고 monocular, stereo, RGB-D 입력에 대해 (semi-)dense maps을 출력
- Semi-direct approaches
 - indirect + direct

⇒ 이들은 수십년간 발전해왔지만 monocular settings에서 handcrafted modules과 정확한 calibration에 의존해야 하는 한계가 있음

Classical and Learning-based Visual SLAM

- 딥러닝의 등장

- handcrafted module들이 점점 학습기반으로 교체되기 시작함

- 강건한 feature tracking을 위한 data-driven descriptors, matchers
 - RGB video에서 pose, depth를 추정하는 end-to-end networks
 - hybrid methods (learned priors + geometric backends)

- 더 최근에는

- learning-based SLAM에서 DBA(differentiable Dense Bundle Adjustment)가 다뤄짐
 - DROID-SLAM, DPVO, GO-SLAM

Visual Foundation Models for 3D Geometry

- 최근 GFM은 uncalibrated image로부터 dense 3D structure를 직접 예측하는데 강한 성능을 보임
- DUS3R
 - 이미지쌍을 기반으로 해당 예측을 수행하는 첫 번째 시도
 - 후속 연구들은 DUS3R를 dynamic scenes로 확장
- MAS3R
 - SfM, real-time dense SLAM과 같은 downstream 시스템들에서 사용될 수 있는 per-pixel descriptors를 소개
- VGGT
 - 임의의 multi-view 입력에 일반화되어, intrinsics, poses, depth, tracks, dense pointmaps를 한 번의 feed-forward pass에서 예측

⇒ 최근 이러한 foundation model들이 SLAM에 적용됨

Visual Foundation Models for 3D Geometry




- MAST3R-SLAM
 - reconstruction prior를 활용한 최초의 실시간 dense monocular SLAM
 - 하지만 인접 two-view 입력에 의존하여 시차 다양성이 제한되고, 어려운 움직임을 보이는 일관되지 않은 구조를 초래
- VGGT-SLAM
 - VGGT를 online settings으로 확장한 방식으로, 16~32개의 연속 프레임들을 하나의 submap으로 구성하고 이들을 $SL(4)$ 최적화로 정렬함
- VGGT-Long
 - VGGT-SLAM을 더 큰 60~75개의 frame window로 키우고, $Sim(3)$ 보정을 추가

⇒ 이러한 submap 기반 방법들은 foundation models로 online SLAM을 가능하게 했지만, 몇 가지 문제가 있었음

- 주로 N 개의 가장 인접한 view들에만 의존하며, 이는 keyframe이 선택될 때 중복되는 겹침(redundant overlap)을 포함할 수 있음
- 충분한 geometric coverage를 보장하기 위한 크고, 고정된 크기의 window가 필요하며, 이는 SLAM에서 연속적인 multi-view tracking이 아닌 deferred submap registration을 다루게 함

AIM-SLAM

- 이러한 문제들을 기반으로, adaptive & informative 방식의 overlap-aware keyframe prioritization method를 설계하였고, 이는 VGGT의 기하학적 정밀도(fidelity)를 보존하면서 중복된 추론을 피하게 하고 informative view들만 남기게 함




Legend:
⊠ : Keyframe ⊠ : Current frame ⊠ : Multi-view keyframe → : Camera trajectory
⊠ : Chunk of keyframes

- 인접 frame에 의존하는 방식 대비 이점
 - 기하학적 일관성 향상
 - scale drift 완화
 - 다양한 scene들에 걸쳐 일관된 dense reconstruction

⇒ 결론적으로 제안된 방법은 고정 크기의 window를 가지는 시스템들보다 더 확장가능한 해결책이 됨


AIM-SLAM

- whole framework



Adaptive Multi-view Prioritization via SIGMA Module


- SIGMA module



- input subset $\mathcal{W}$ 을 위한 candidate set $\mathcal{W}_v$ 을 정의함
- $\mathcal{W}_v$ 를 구성하기 위해 SIGMA 모듈을 제안하며, 이는 3단계로 구성됨
 1. Geometry-based Initial Subset Construction
 2. Information-driven Subset Re-ranking
 3. Adaptive Subset Activation with Stability Criterion

Geometry-based Initial Subset Construction

- voxel-indexed keyframe map



- compute overlap score & initialize $\mathcal{W}_v$ with top-n

$$O(I_k, I_i) = |\underline{v(I_k)} \cap v(I_i)|, I_i \in \mathcal{F} \setminus \{I_k\},$$

I_k 를 제외한 나머지 historical keyframes

- $O(\cdot, \cdot)$: overlap score
- $v(I)$: I 에 의해 관측된 voxel들의 집합
- I_i : keyframe 집합 $\mathcal{F} \setminus \{I_k\}$ 에 있는 keyframe

⇒ but, it can't reflect informativeness

Information-driven Subset Re-ranking

- EKF update ($\mathbf{P}_k = \mathbf{P}(\mathbf{x}_k)$)

$$\mathbf{P}_{k \rightarrow j}^+ = \mathbf{P}_k^- - \mathbf{P}_k^- \mathbf{J}_r^\top (\mathbf{R} + \mathbf{J}_r \mathbf{P}_k^- \mathbf{J}_r^\top)^{-1} \mathbf{J}_r \mathbf{P}_k^- ,$$

- pixel noise + fused confidence
- Gaussian Assumption

- $\mathbf{P}_k^-$: I_k 에서 관측된 3D point $\mathbf{x}_k$ 의 **prior covariance**
- $\mathbf{P}_{k \rightarrow j}^+$: I_j 를 추가한 이후의 **posterior covariance**
- $\mathbf{J}_r$: I_k 를 candidate view I_j 에 재투영했을 때의 ray-based residual의 Jacobian
- $\mathbf{R}$: measurement covariance (full 3×3 covariance)

2D image space noise + VGGT's depth confidence

I_j 를 실제로 추가한다면, I_k 의 3D point uncertainty를 얼마나 감소시키는가?

- Compute information gain & Re-rank $\mathcal{W}_v$

$$\Gamma(I_k, I_j) = \sum_{\mathbf{x}_k \in \Omega_{k \rightarrow j}} \frac{1}{2} \log \frac{\det(\mathbf{P}_k^-)}{\det(\mathbf{P}_{k \rightarrow j}^+)},$$

그 감소시킨 수치가 얼마나 큰가?

- $\Gamma(\cdot, \cdot)$: information gain score
- $\Omega_{k \rightarrow j}$: 재투영 이후 valid point set
- $\det(\cdot)$: determinant

연산량을 고려하여 low-confidence points
만 subset으로 선택해 re-ranking 진행

⇒ but, we don't have to activate all of them

Adaptive Subset Activation with Stability Criterion

- Statistical stability assessment

- $\mathbf{b}_0 \in \mathbb{R}^M$: 기존 residuals을 정규화하여 얻은 whitened residual vector
- $\mathbf{A}_0 \in \mathbb{R}^{M \times p}$: 현재 linearization에 대응하는 Jacobian

$$\kappa = \frac{\mathbf{b}_0^\top \mathbf{b}_0}{M - \text{rank}(\mathbf{A}_0)} \sim \chi^2(M - \text{rank}(\mathbf{A}_0)),$$

현재 선택한 multi-view 구성이 correspondence geometry를 noise 수준까지 잘 설명하고 있는가?

(GPT 5.6 High)

- κ : reduced Chi-square statistic

- $\kappa \leq 1.0$

$$\mathcal{W}_0 = \{I_f, I_k, I_b\}$$

→ 구성이 stable하다고 여겨지고, window를 default three views로 유지

- $\kappa > 1.0$

→ 추가적인 keyframe $I_v \in \mathcal{W}_v$ 를 추가하고, multi-view 최적화 후에 κ 를 재평가

- $\mathcal{W}$ 구성

- 만약 추가한 I_v 가 κ 를 늘리면, $\mathcal{W}$ 를 다시 default three views($\mathcal{W}_0$)로 초기화
- 만약 추가한 I_v 가 κ 를 줄이면, $\mathcal{W}$ 에 I_v 를 추가한채로 유지

SIGMA module 정리

1. Geometry-based Initial Subset Construction

- voxel-indexed keyframe map을 통해 overlap score를 구하고, 해당 score가 높은 top-N개의 keyframe들을 정렬하여 초기 $\mathcal{W}_v$ 를 형성

2. Information-driven Subset Re-ranking

- EKF update form을 통해, $\mathcal{W}_v$ 내부 keyframe들이 I_k 의 3D point uncertainty를 얼마나 줄이는지를 수식화
- 수식 결과를 기반으로 이들의 information gain을 구한뒤, $\mathcal{W}_v$ re-ranking 진행


3. Adaptive Subset Activation with Stability Criterion

- κ 가 1.0을 초과할때만 $\mathcal{W}_v$ 에서 가장 앞에 있는 keyframe I_v 를 $\mathcal{W}$ 에 추가

⇒ SIGMA 모듈은 초기 $\mathcal{W}_0$ 에 추가할 keyframe을 걸러내는 전처리 과정

Joint Multi-view Sim(3) Optimization with Hybrid Residual

- Tracking and Keyframe Management
 - MASt3R-SLAM의 ray-matching 사용 (but, extended to multi-view)



$$\mathbf{p}^* = \arg \min_{\mathbf{p}} \|\psi([\mathbf{X}_i^i]_{\mathbf{p}}) - \psi(\mathbf{x})\|^2.$$

$$\|\psi_1 - \psi_2\|^2 = 2(1 - \cos \theta), \quad \cos \theta = \psi_1^T \psi_2.$$

(MASt3R-SLAM)

- 현재 frame I_f 에서 유효한 correspondence의 비율이 일정 threshold 미만이면, 해당 프레임을 새로운 keyframe으로 선정하고 $\mathcal{F}$ 에 추가

Joint Multi-view Sim(3) Optimization with Hybrid Residual

- Optimization

$$\mathcal{W}_{\text{opt}} = \{I_m, \dots, I_k, I_f\} \quad \text{기존 } \mathcal{W} \text{를 reverse하여 정의 (시간에 오름차순)}$$

$$\mathcal{T}_{\mathcal{W}_{\text{opt}}} = [\mathbf{T}_v^m, \dots, \mathbf{T}_f^k] \quad \text{relative transformation (pose)}$$

- 각 frame쌍 $(I_i, I_j) \in \mathcal{W}_{\text{opt}}$ 에 대해, ray 및 pixel 기반 reprojection항을 결합한 residual을 정의

$$\begin{aligned} \mathbf{r}_{ij} = & \left(\Psi_{\text{ray}}(\mathbf{X}_{i|i}) - \Psi_{\text{ray}}(\mathbf{T}_j^i \mathbf{X}_{j|j}) \right) \\ & + \left(\Psi_{\pi}(\mathbf{K}_i, \mathbf{X}_{i|i}) - \Psi_{\pi}(\mathbf{K}_i, \mathbf{T}_j^i \mathbf{X}_{j|j}) \right), \end{aligned}$$

- $\mathbf{r}_{ij}$: reprojection residual
- $\Psi_{\text{ray}}(\cdot)$: 3D point를 unit sphere에 투영하는 ray-normalization function
- $\Psi_{\pi}(\cdot)$: VGGT로 예측한 intrinsics $\mathbf{K}_i$ 를 이용한 pinhole camera projection

Joint Multi-view Sim(3) Optimization with Hybrid Residual

- Optimization

$$\mathbf{r} = \sum_{(I_i, I_j) \in \mathcal{W}_{\text{opt}}} \mathbf{r}_{ij} = \sum_{(I_i, I_j) \in \mathcal{W}_{\text{opt}}} \left(\sum_{(a,b) \in \mathbf{m}_{i \rightarrow j}} \left(\frac{\mathbf{r}_{ij}^{ab}}{{}^{ab}w_{ij}} \right)_{\rho} \right), \quad \text{for local consistency}$$

- $\mathbf{m}_{i \rightarrow j}$: i 번째 프레임에서 j 번째 프레임으로의 pixel correspondences 집합
- $\mathbf{r}_{ij}^{ab}$: 각 correspondence 쌍에 정의된 hybrid residual
- $(\cdot)_{\rho}$: Huber norm
- ${}^{ab}w_{ij}$: per-point residual weight



VGGT's per-pixel confidence의 geometric mean으로 정의

Joint Multi-view Sim(3) Optimization with Hybrid Residual

- Optimization

- gauge freedom을 해결하기 위해 I_m 을 고정
- keyframe pointmap들은 confidence-weighted averaging으로 융합(fuse)됨

$$\tilde{\mathbf{X}}_k^k \leftarrow \frac{\tilde{\mathbf{C}}_k^k \tilde{\mathbf{X}}_k^k + \mathbf{C}_f^k (\mathbf{T}_{kf} \mathbf{X}_f^k)}{\tilde{\mathbf{C}}_k^k + \mathbf{C}_f^k}, \tilde{\mathbf{C}}_k^k \leftarrow \tilde{\mathbf{C}}_k^k + \mathbf{C}_f^k. \quad (\text{MASt3R-SLAM})$$

fused confidence

- VGGT로 예측한 focal length들도 반복적으로 평균됨
- loop closure
 - VGGT의 first-layer token z_k 을 재사용하여 loop closure 구현
 - loop candidate들은 저장된 token database에 cosine similarity를 비교해 retrieve되며, top-2 matches를 loop edge set $\mathcal{E}_{\mathcal{L}_k}$ 로 정의한 후에 z_k 를 future query에 추가

- pose graph


$$\mathcal{E}_{\mathcal{G}} \leftarrow \mathcal{E}_{\mathcal{G}} \cup (\mathcal{E}_{\mathcal{S}_k} \cup \mathcal{E}_{\mathcal{L}_k})$$

whole keyframes (아마도?)

- $\mathcal{E}_{\mathcal{G}}$: edge set
- $\mathcal{E}_{\mathcal{S}_k}$: sequential edges
- $\mathcal{E}_{\mathcal{L}_k}$: loop edges

for global consistency

Pipeline Review



Camera Pose Estimation

Method		TUM RGB-D									Avg.
		360	desk	desk2	floor	plant	room	rpy	teddy	xyz	
Calib.	DeepV2D [59]	0.243	0.166	0.379	1.653	0.203	0.246	0.105	0.316	0.064	0.375
	DeepFactors [60]	0.159	0.170	0.253	0.169	0.305	0.364	0.043	0.601	0.035	0.233
	DROID-SLAM [11]	0.111	0.018	0.042	0.021	0.016	0.049	0.026	0.048	0.012	0.038
	DPV-SLAM [61]	0.112	0.018	0.029	0.057	0.021	0.330	0.030	0.084	0.010	0.076
	MASt3R-SLAM [8]	0.049	0.016	0.024	0.025	0.020	0.061	0.027	0.041	0.009	0.030
Uncalib.	DROID-SLAM [11]	0.202	0.032	0.091	0.064	0.045	0.918	0.056	0.045	0.012	0.158
	MUS3R-VO [7]	0.078	0.040	0.046	0.091	0.040	0.099	0.043	0.042	0.013	0.055
	VGGT-Long [10]	0.053	0.064	0.060	0.111	0.064	0.170	0.036	0.127	0.047	0.081
	VGGT-SLAM [9]	0.071	0.025	0.040	0.141	0.023	0.102	0.030	0.034	0.014	0.053
	MASt3R-SLAM [8]	0.070	0.035	0.055	0.056	0.035	0.118	0.041	0.114	0.020	0.060
	AIM-SLAM (ours)	0.050	0.017	0.028	0.024	0.026	0.062	0.021	0.039	0.010	0.031


TUM RGB-D

Method		EuRoC											Avg.
		V101	V102	V103	V201	V202	V203	MH01	MH02	MH03	MH04	MH05	
Calib.	DeepV2D [59]	0.981	0.801	1.570	0.290	2.202	2.743	0.739	1.144	0.752	1.492	1.567	1.298
	DeepFactors [60]	1.520	0.679	0.900	0.876	1.905	1.021	1.587	1.479	3.139	5.331	4.002	2.040
	DROID-SLAM [11]	0.037	0.013	0.019	0.017	0.010	0.013	0.013	0.012	0.022	0.048	0.044	0.022
	DPV-SLAM [61]	0.035	0.008	0.015	0.020	0.011	0.040	0.013	0.016	0.022	0.043	0.041	0.024
	MASt3R-SLAM [8]	0.040	0.019	0.027	0.020	0.025	0.043	0.023	0.017	0.057	0.113	0.067	0.041
Uncalib.	DROID-SLAM [11]	0.465	1.679	1.439	0.878	1.414	1.895	0.154	0.256	1.010	0.719	0.762	0.970
	MUS3R-VO [7]	0.489	0.287	0.554	0.123	0.109	0.252	0.265	-	0.909	0.741	0.828	0.456 [†]
	VGGT-Long [10]	0.139	0.165	0.198	0.202	0.130	0.137	0.579	0.745	0.428	0.713	0.605	0.367
	VGGT-SLAM [9]	0.098	0.184	0.353	0.068	0.903	0.431	0.400	0.701	3.599	-	-	0.749 [†]
	MASt3R-SLAM [8]	0.101	0.134	0.096	0.133	0.100	0.170	0.180	0.124	0.156	0.282	0.327	0.164
	AIM-SLAM (ours)	0.081	0.059	0.069	0.057	0.053	0.060	0.055	0.076	0.058	0.115	0.114	0.072

EuRoC

왜 EuRoC에서는 calibrated method 성능을 못따라잡을까?

Dense Reconstruction



object의 fine detail을 잘 살리고,
ghosting artifacts가 적음

TUM RGB-D


EuRoC

stable informative view selection과
dense surface coverage간에 trade-off


Method	EuRoC			TUM RGB-D		
	Accuracy	Completion	Chamfer	Accuracy	Completion	Chamfer
VGGT-Long [10]	<u>0.106</u>	0.119	0.112	<u>0.094</u>	<u>0.107</u>	<u>0.100</u>
VGGT-SLAM [9]	0.246	0.216	0.231	0.109	0.127	0.118
MASt3R-SLAM [8]	0.108	0.072	0.090	0.097	0.113	0.105
AIM-SLAM (ours)	0.103	<u>0.102</u>	<u>0.102</u>	0.063	0.098	0.081

Ablation Study

most recent consecutive keyframes to form input subset in prior methods (MASt3R-SLAM, VGGT-SLAM, VGGT-Long)



(a) TUM RGB-D



(b) EuRoC

larger baselines, rapid viewpoint changes를 포함하는 **EuRoC**에서 두 방법이 성능 차이를 크게 보임

이는 SIGMA 모듈 기반 방법이 recency기반 방법보다 더 유익한 keyframe들을 일관적으로 활용하기 때문임

Method	ATE RMSE	
	EuRoC	TUM RGB-D
Ray only	0.138	0.061
Projection only	0.081	0.032
Hybrid (ray + projection)	0.072	0.031


Ray only는 pixel-level constraints가 부족하여 geometric precision 성능을 제한

Projection-only는 오차를 줄이긴 했지만, 여전히 calibration noise에 민감

두 residual을 합친 hybrid가 가장 좋은 성능을 보이며, 상보성을 강조

(MASt3R-SLAM과 정반대 결과?)

Effect of SIGMA module



SIGMA module reduces uncertainty!

Conclusion

- GFM을 활용한 dense monocular SLAM framework + uncalibrated settings
- SIGMA module
 - sparse하지만 겹치는 구역이 많고 정보가 많은 keyframe subset의 우선순위를 adaptive하게 정함
 - 우선순위화 된 multi-view subset은 $\text{Sim}(3)$ space에서 동시에 최적화되어, short-, mid-term drift를 모두 줄임
 - 해당 요소들은 uncalibrated conditions 정확한 pose estimation 및 기하학적 일관된 dense reconstruction을 가능하게 하며, GFM 기반 SLAM에 대해 확장가능한 solution을 더 제공함

한계

- VGGT inference에 의존
 - 본인들 환경에서 대략 3 Hz의 runtime이 나옴
- VGGT inference를 제외하면, **AIM-SLAM**의 나머지 요소들은 17 Hz로 돌아감

Future work

- 경량화 진행 예정 (다른 GFM으로 바뀌어서 가속화)

왜 잘됐는가?

- SIGMA module을 통해 uncertainty를 고려한 적응형 subset을 구성한 점
 - 특히 새 keyframe 도입 + multi-view optimization을 반복해가면서 최적의 multi-view subset을 구성해나가는 것이 인상깊었음
- 기존 MASTR-SLAM은 ray-based residual만 사용했지만, 여기서는 point-based를 추가해 hybrid residual을 사용함 (ablation으로 성능 향상 증명)
 - MAST3R-SLAM의 ray-based, point-based랑은 다른건가? (성능이 정반대)
- 3D recons 결과에서 다른 method 대비 ghosting artifact가 확실히 줄어들음
 - confidence가 낮은 I_k 의 3D point에 대해서 uncertainty를 낮추는 방향으로 I_v 를 추가
 - confidence-weighted averaging을 fused confidence update
 - 이는 re-ranking의 prior로 다시 이어져서 re-ranking진행